

Resenha Crítica: Vieses Algorítmicos em Recrutamento Automatizado

Vinicius Maestrelli Wiggers¹

¹ Universidade Interdimensional Tuiuti do Paraná
Curitiba – PR – Brasil

vinicius.wiggers@utp.edu.br

Resumo. *Este trabalho apresenta uma resenha crítica sobre os vieses algorítmicos em sistemas de recrutamento automatizado, com base no artigo de Zhisheng Chen (2023). Descrevem-se os principais pontos do artigo, discutem-se exemplos reais de discriminação algorítmica, analisam-se impactos sociais e éticos e propõem-se melhorias e regulamentações para mitigar injustiças nos processos seletivos baseados em IA.*

1. Resumo do Artigo

Chen (2023) investiga o fenômeno da discriminação algorítmica em ferramentas de recrutamento baseadas em IA, destacando benefícios como aumento de eficiência e redução de custos, mas evidenciando graves riscos de viés relacionados a gênero, raça e outros atributos sensíveis [Chen 2023]. A análise baseia-se em revisão de literatura e entrevistas com desenvolvedores e usuários de sistemas de seleção automatizada, identificando que algoritmos treinados em dados históricos enviesados reproduzem e amplificam preconceitos pré-existent. O autor propõe soluções técnicas (balanceamento de dados, explicabilidade) e institucionais (comitês de ética, governança) para mitigar tais efeitos.

2. Discussão Crítica

Casos reais ilustram a perpetuação de discriminação. Em 2018, a Amazon abandonou ferramenta interna de seleção de currículos ao descobrir que ela penalizava candidatas mulheres, pois fora treinada majoritariamente com dados de funcionários masculinos bem-sucedidos [Dastin 2018]. O algoritmo rebaixava currículos que mencionavam termos associados a mulheres, refletindo enviesamento histórico. Outro exemplo é o uso de nomes afro-americanos em candidaturas, que recebem em média 50% menos convites para entrevistas em estudos de campo [Bertrand and Mullainathan 2004]. Plataformas de entrevistas por vídeo, como a HireVue, empregam IA para avaliar expressões faciais e entonações, mas enfrentam críticas de falta de transparência e reforço de padrões homogêneos de perfis “ideais” [Center 2019].

3. Impactos Sociais e Éticos

O uso massivo de IA em recrutamento – adotado por mais de 90% de grandes empresas – pode ampliar desigualdades sociais ao excluir sistematicamente grupos sub-representados [OECD 2019]. Vieses algorítmicos ferem princípios de equidade, desperdiçam talentos e prejudicam a diversidade, reduzindo potencial de inovação. Do ponto de vista ético, a opacidade algorítmica dificulta justiça e responsabilização: candidatos rejeitados não têm

acesso aos critérios de decisão. Legalmente, normas como o GDPR europeu garantem o “direito à explicação” e avaliação de impacto para sistemas de alto risco [gdp 2016], e legislações como a Local Law 144/2021 de Nova Iorque exigem auditorias independentes anuais para ferramentas de contratação automatizada [nyc 2021].

4. Sugestões de Melhorias e Regulamentações

- **Balanceamento de dados:** construir conjuntos representativos e aplicar técnicas de oversampling e geração de dados sintéticos para corrigir enviesamentos (por exemplo, métodos apresentados em [Buolamwini and Gebru 2018, Pei et al. 2017]).
- **Transparência algorítmica:** adotar práticas como model cards [Mitchell et al. 2019], logs de decisão abertos e ferramentas interativas (ex.: What-If Tool [Wexler et al. 2019]) para auditoria contínua.
- **Neutralização de atributos sensíveis:** remover informações demográficas de currículos ("blinding") ou avaliar subgrupos separadamente ("decoupling") para evitar critérios espúrios.
- **Governança interna:** instituir comitês de ética em IA, auditorias periódicas e equipes multidisciplinares de RH e TI comprometidas com a diversidade.
- **Regulamentação externa:** incentivar legislações que classifiquem sistemas de recrutamento como de "alto risco", impondo certificações e auditorias por entidades independentes, conforme proposto na AI Act da UE [OECD 2019] e na lei de Nova Iorque [nyc 2021].
- **Educação e padrões:** capacitar recrutadores para interpretação crítica de resultados de IA e estabelecer certificações profissionais para fornecedores de soluções de seleção automatizada.

5. Conclusão

A IA no recrutamento oferece ganhos de eficiência e objetividade, mas sem salvaguardas técnicas e éticas pode cristalizar preconceitos sob a aparência de neutralidade. O futuro do mercado de trabalho dependerá da combinação entre inovação e inclusão: adotar dados balanceados, promover transparência e responsabilização, e regulamentar adequadamente garantirá que a IA seja aliada na promoção da equidade e não um instrumento de discriminação.

Referências

- (2016). Regulation (eu) 2016/679 (general data protection regulation). Official Journal of the European Union. Acessado em 14 de junho de 2025.
- (2021). Local law 144/2021: Automated employment decision tools. New York City Local Laws. Acessado em 14 de junho de 2025.
- Bertrand, M. and Mullainathan, S. (2004). Are emily and greg more employable than lakisha and jamal? a field experiment on labor market discrimination. *American Economic Review*, 94(4):991–1013.
- Buolamwini, J. and Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency (FAT*)*, pages 77–91.

- Center, E. P. I. (2019). Request for commission action regarding automated personality and facial recognition assessments in employment decisions. EPIC. Acessado em 14 de junho de 2025.
- Chen, Z. (2023). Ethics and discrimination in artificial intelligence-enabled recruitment practices. *Humanities and Social Sciences Communications*, 10:567.
- Dastin, J. (2018). Amazon scraps secret ai recruiting tool that showed bias against women. Reuters. Online; acessado em 14 de junho de 2025.
- Mitchell, M., Wu, S., Zaldivar, M., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., and Gebru, T. (2019). Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, pages 220–229.
- OECD (2019). Oecd principles on artificial intelligence. OECD. Acessado em 14 de junho de 2025.
- Pei, K., Cao, Y., Yang, J., and Jana, S. (2017). Deepxplore: Automated whitebox testing of deep learning systems. In *Proceedings of the 2017 ACM Symposium on Operating Systems Principles (SOSP)*, pages 1–18.
- Wexler, J., Pushkarna, M., Bolukbasi, T., Wattenberg, M., Viegas, F., and Fortunato, M. (2019). The what-if tool: Interactive probing of machine learning models. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, pages 1–12.